

RAG Application Mini-Hackathon

Contoso Electronics Product Support Assistant

Microsoft Foundry (Azure AI Studio) | GPT-4o + File Search

ส่วน A ความเข้าใจ

RAG คืออะไร?

RAG (Retrieval-Augmented Generation) คือสถาปัตยกรรม AI ที่แบ่งการทำงานออกเป็น 2 ขั้นตอนหลัก ได้แก่ การค้นหาข้อมูล (Retrieval) และการสร้างคำตอบ (Generation) เมื่อผู้ใช้ถามคำถาม ระบบจะค้นหาเอกสารที่เกี่ยวข้องจาก knowledge base ก่อน จากนั้นส่งข้อมูลเหล่านั้นให้ Language Model ใช้เป็น context ในการสร้างคำตอบ

ทำไมต้องใช้ RAG สำหรับปัญหานี้?

Contoso Electronics มีสินค้ากว่า 40 รายการ แต่ละรายการมี spec เฉพาะ ราคา นโยบายคืนสินค้า และรายละเอียดที่แตกต่างกัน ซึ่ง LLM ทั่วไปไม่มีข้อมูลเหล่านี้ใน training data และหากให้ AI ตอบจาก general knowledge จะเกิดการ hallucinate คำที่ไม่ถูกต้องได้ RAG สามารถแก้ปัญหานี้โดยบังคับให้ AI ดึงข้อมูลจากเอกสารจริงเท่านั้น ทำให้คำตอบแม่นยำ ตรวจสอบได้ และอัปเดตได้โดยไม่ต้อง retrain โมเดลใหม่

ปัญหาที่พบและวิธีแก้ไข

ในระหว่างการทดสอบพบปัญหาหลัก 4 ประเภท ดังนี้

ประเภทปัญหา	อาการที่พบ	วิธีแก้
Version Conflict	AI ตอบข้อมูลจาก v1 file เช่น บอกว่า BrewMaster ไม่รองรับ cold brew ทั้งที่ version ใหม่รองรับ	ลบ v1 files ออกจาก Vector Store และเพิ่ม rule ให้ treat v1 as invalid
Wrong Product Mapping	ถามเรื่อง SoundPods แต่ AI ตอบด้วยข้อมูล SonicBuds แทน	เพิ่ม FIRST CHECK และตัวอย่าง ≠ เช่น SoundPods ≠ SonicBuds
Spec Inference	AI นำ Bluetooth 5.2 มาอนุมานว่าระยะ ~10 เมตร ทั้งที่ไม่มีข้อมูลนั้นในเอกสาร	เพิ่ม rule ห้าม infer หรือ derive คำตอบจากข้อมูลที่มีอยู่
Version Mention	แม้ตอบถูกว่า BrewMaster รองรับ cold brew แต่ยังไม่พูดถึงรุ่นก่อนหน้าด้วย	ปรับ rule เป็น respond as if v1 file does not exist

System Instruction สุดท้ายที่ใช้

You are a Product Support Assistant for Contoso Electronics.
Your ONLY knowledge source is the uploaded product documentation files.
You should always answer in the same language as the question.

FIRST CHECK Do this before ANYTHING else:
Identify the exact product name in the question.
If that exact name does not exist in the documentation,

STOP and respond only:

"There is no Contoso product called [name] in the product catalog." or in the same language as question.

- "SoundPods" is NOT "SonicBuds"
- "SmartLock Pro" is NOT "WatchGuard Pro"
- "AirCool" is NOT "BreatheEasy"

Do NOT proceed to answer with any other product's specs.

Core Rules:

1. ALWAYS answer from product documents only. Never use general knowledge or assumptions.

2. SPEC QUESTIONS: Quote exact values (numbers, units, model codes, prices).

3. VERSION CONFLICT: If a product has both a current file and a v1 file (e.g., mechanical-keyboard.md vs mechanical-keyboard-v1.md), ALWAYS use the CURRENT version (non-v1 file). Ignore v1 data entirely.

4. MULTI-MODEL PRODUCTS: If a product line has multiple models (e.g., FitPulse Ultra and FitPulse Lite, SonicBuds Pro and SonicBuds Lite), you MUST address ALL models and clearly differentiate them. Never answer about just one model when multiple exist.

5. MISSING SPEC: If a specific spec is asked but not listed in the documentation, respond:

"The [product] documentation does not specify [the spec]."

Then mention what related specs ARE available

(e.g., battery runtime instead of mAh).

Do NOT guess or estimate.

Do NOT infer or derive the answer from related data

(e.g., if asked about Bluetooth range and the doc only

states "Bluetooth 5.2", do NOT assume or state a range just say the range is not specified in the documentation).

6. NON-EXISTENT PRODUCT: If the product name does not appear in any documentation, respond:

"There is no Contoso product called [name] in the product catalog."

You may suggest similar products that DO exist, but do NOT describe the non-existent product.

7. POLICY QUESTIONS: Cite exact fees, timeframes, and conditions from the document. Never generalize.

8. NEVER hallucinate specs, prices, model numbers, or features not in documents.

ส่วน B กลยุทธ์การทดสอบ

นอกเหนือจาก 40 ข้อที่ให้มา ควรทดสอบคำถามเพิ่มเติมอีกอย่างน้อย 3 ประเภท ดังนี้

#	คำถาม	เหตุผลที่ควรทดสอบ	Expected behavior
1	TypeForce keyboard ใช้กับ iPad ได้ไหม?	ทดสอบ cross-device compatibility ที่ไม่ได้รับรู้อย่างชัดเจนในเอกสาร แต่สามารถอนุมานจาก Bluetooth spec ได้ ต้องดูว่า AI จะ infer หรือ respond ตาม doc เท่านั้น	ตอบได้เฉพาะสิ่งที่มีในเอกสาร เช่น รองรับ Bluetooth 5.2 ส่วน iPad compatibility ไม่มีระบุในเอกสาร
2	ต้องการเครื่องทำกาแฟที่ดีที่สุด แนะนำรุ่นไหน?	ทดสอบ recommendation/opinion question ที่ต้องการให้ AI ไม่แสดงความคิดเห็นส่วนตัวแต่ให้ข้อมูลเปรียบเทียบจากเอกสารเท่านั้น	ไม่ตัดสินใจแทน แต่แสดงรายการสินค้าที่มีพร้อม spec เพื่อให้ลูกค้าตัดสินใจเอง
3	ฉันคืนสินค้าได้กี่วัน? (ไม่ระบุสินค้า)	ทดสอบ ambiguous policy question ที่ต้องการซื้อสินค้าชัดเจน เพราะนโยบายต่างกันในแต่ละสินค้า (เช่น PostureFlex 30 วัน, HushElite 30 วัน แต่ค่า restocking ต่างกัน)	ถามกลับว่าหมายถึงสินค้าใด ไม่ตอบแบบ generalize
4	ซื้อ SmoothGlide มาแล้ว 35 วัน จะคืนได้ไหม?	ทดสอบ edge case situational ที่อยู่นอกระยะคืนสินค้า ต้องดูว่า AI ตอบได้ถูกต้องตาม policy ว่าเกิน 30 วันแล้ว	ระบุชัดเจนว่าเกิน return window แล้ว ไม่สามารถคืนได้

ส่วน C หลักการออกแบบ RAG

หากต้องออกแบบ RAG system เอง จะใช้หลักการดังต่อไปนี้

Use Case

ระบบ AI Assistant สำหรับตอบคำถามของนักศึกษาเกี่ยวกับรายวิชาในมหาวิทยาลัย เพื่อช่วยแบ่งเบาภาระของอาจารย์และ TA ที่ต้องตอบคำถามซ้ำๆ เช่น เหนื่อยการให้คะแนน กำหนดส่งงาน วิธีการสอบ และข้อมูล syllabus ของแต่ละรายวิชา

ข้อมูลที่ต้องการ

- Syllabus และ course outline ของแต่ละรายวิชา (PDF หรือ Markdown)
- ประกาศและ announcement จากอาจารย์ พร้อม metadata: วิชา, วันที่ประกาศ, ภาคการศึกษา
- FAQ ที่อาจารย์หรือ TA รวบรวมไว้จากคำถามที่พบบ่อยในอดีต
- ต้องมีการ versioning ตามภาคการศึกษา เพื่อไม่ให้ข้อมูลปีก่อนปนกับปีปัจจุบัน

ความคาดหวัง

- ตอบคำถามได้ตรงตาม syllabus และ announcement จริง ไม่เดา
- ลด workload ของ TA ในการตอบคำถามซ้ำๆ ลงได้อย่างน้อย 60 - 70%
- อ้างอิงแหล่งที่มาได้เสมอ เช่น "ตาม syllabus วิชา X หน้า 3"
- เมื่ออาจารย์เปลี่ยนแปลง syllabus หรือออกประกาศใหม่ ระบบต้องสะท้อนข้อมูลใหม่ได้ทันที

Challenges และปัญหาที่คิดว่าจะเจอ

1. Semester Versioning

syllabus ปีนี้กับปีก่อนอาจมีชื่อวิชาเหมือนกัน แต่เกณฑ์คะแนนต่างกัน ต้องกรองให้ดึงเฉพาะภาคการศึกษาปัจจุบันเท่านั้น

2. Ambiguous Questions

นักศึกษามักถามกว้างๆ เช่น "สอบยังไม้ง" โดยไม่ระบุรายวิชา ระบบต้องถามกลับให้ระบุวิชาก่อนตอบ

3. Out-of-scope Questions

นักศึกษาอาจถามเรื่องที่ไม่มีในเอกสาร เช่น "อาจารย์ให้เกรดง่ายไหม" ระบบต้องปฏิเสธได้อย่างสุภาพโดยไม่เดาคำตอบ

4. Document Freshness

อาจารย์อาจแก้ deadline กะทันหัน ระบบต้องดึง announcement ล่าสุดได้ทันที และไม่ตอบตาม syllabus เก่าที่ถูก supersede แล้ว